

**ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ**  
**ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ**  
**ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ**

**Ψηφιακή Επεξεργασία Εικόνας**  
**(8ο ΕΞΑΜΗΝΟ)**

**-3<sup>η</sup> Εργασία-**

**Image Segmentation**

**Ονοματεπώνυμο: Ματσούκας Βασίλειος**

**AEM: 8743**

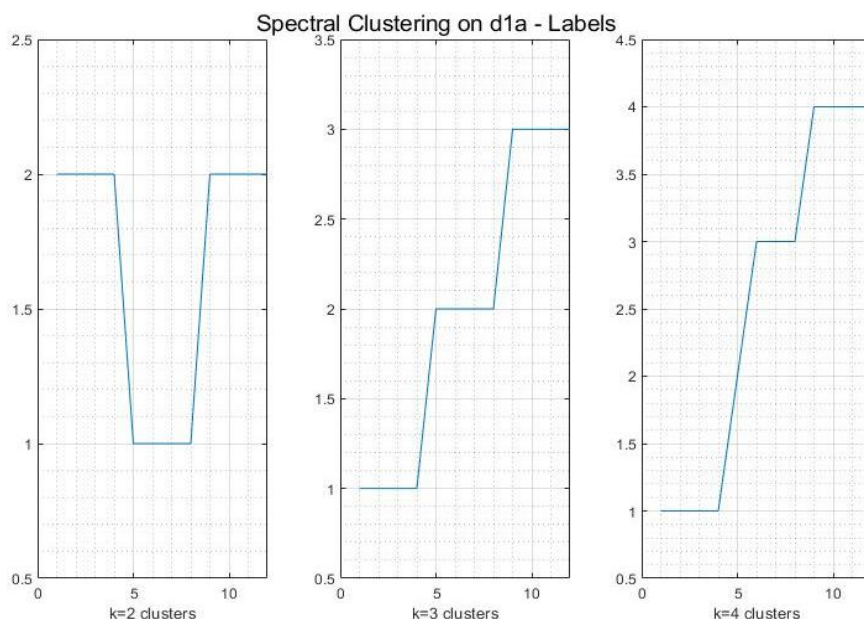
**Email: [vmatsouk@auth.gr](mailto:vmatsouk@auth.gr)**

**Παρουσίαση αποτελεσμάτων και συμπερασμάτων ανά ενότητα**

**Ενότητα 1**

Για αυτή την ενότητα παρουσιάζουμε την `mySpectralClustering`. Η συνάρτηση δέχεται ως όρισμα έναν affinity πίνακα (τετράγωνο και συμμετρικό) που περιγράφει τον γράφο και τον αριθμό  $k$  των clusters που θέλουμε να δημιουργηθούν. Υπολογίζει τον μη-κανονικοποιημένο Λαπλασιανό πίνακα και βρίσκει τις  $k$  μικρότερες ιδιοτιμές του (και τα αντίστοιχα ιδιοδιανύσματα) με τη συνάρτηση `eigs` (και όρισμα `smallestabs`). Για τη διαδικασία της ομαδοποίησης σε  $k$  clusters εφαρμόζεται η  $k$ -means της Matlab χρησιμοποιώντας τα ιδιοδιανύσματα που υπολογίστηκαν. Η συνάρτηση επιστρέφει το διάνυσμα με τις ετικέτες που δείχνουν σε ποιο cluster ανήκει ο κάθε κόμβος.

Η εφαρμογή της ρουτίνας στον affinity `d1a` για  $k=2$ ,  $k=3$ ,  $k=4$  δίνει τα ακόλουθα αποτελέσματα ετικετών, όπως φαίνεται και στο `demo1.m`



**Εικόνα 1.1 Ετικέτες ρουτίνας `mySpectralClustering` στον affinity `d1a`**


Από τη δομή που έχει ο affinity d1a μπορούμε να καταλάβουμε ποιοι κόμβοι θα ομαδοποιηθούν σε ίδιο cluster. Έτσι, για  $k=2$  είναι αναμενόμενο ότι οι κόμβοι 1,2,3,4 και 9,10,11,12 θα ανήκουν στο ίδιο cluster λόγω της ισχυρής σύνδεσής τους (0.900). Για  $k=3$  διαχωρίζονται οι κόμβοι 1,2,3,4 και 9,10,11,12 σε 2 ξεχωριστά cluster. Για  $k=4$  σπάει περαιτέρω το cluster με τους κόμβους 5,6,7,8 σε 5 και 6,7,8 αντίστοιχα.

## Ενότητα 2

Σε αυτή την ενότητα παρουσιάζεται η mySpectralClustering και η Image2Graph. Η Image2Graph είναι υπεύθυνη για την παραγωγή του affinity πίνακα. Δέχεται μια πολύ-κάναλη (n-channel) εικόνα διαστάσεων  $M \times N \times n$  και επιστρέφει τον τετράγωνο και συμμετρικό affinity πίνακα διαστάσεων  $(M \times N) \times (M \times N)$  που περιγράφει το μη-κατευθυντικό γράφο. Κάθε pixel θεωρείται κόμβος (node) του γράφου. Για κάθε pixel  $i$  της εικόνας (που εν γένει είναι διάνυσμα  $n$  στοιχείων) υπολογίζεται η Ευκλείδεια απόσταση της φωτεινότητάς του με κάθε άλλο pixel  $j$  (συμπεριλαμβανομένου και του  $i$ ) και στον affinity πίνακα, στη θέση  $(i, j)$  καταχωρείται η τιμή  $\frac{1}{e^{d(i,j)}}$ , όπου  $d(i,j)$  η Ευκλείδεια απόσταση. Αυτή η τιμή δείχνει πόσο ισχυρές είναι οι συνδέσεις των κόμβων του γράφου (με κριτήριο την ομοιότητα της φωτεινότητας). Όσο πιο ισχυρή είναι η σύνδεση, η τιμή προσεγγίζει την μονάδα, ενώ όσο πιο χαλαρή τότε η τιμή προσεγγίζει το μηδέν. Η συνάρτηση χρησιμοποιεί ένα 4πλό for loop όπου επιλέγει ένα σταθερό pixel  $i$  και το συγκρίνει με κάθε pixel  $j$  κάνοντας αυτή τη δουλειά.


Η εφαρμογή της ρουτίνας mySpectralClustering στις d2a και d2b για κατάτμηση σε 2,3 και 4 clusters φαίνεται στις ακόλουθες εικόνες, και στο demo2.m

### Spectral Clustering on d2a(k=2)



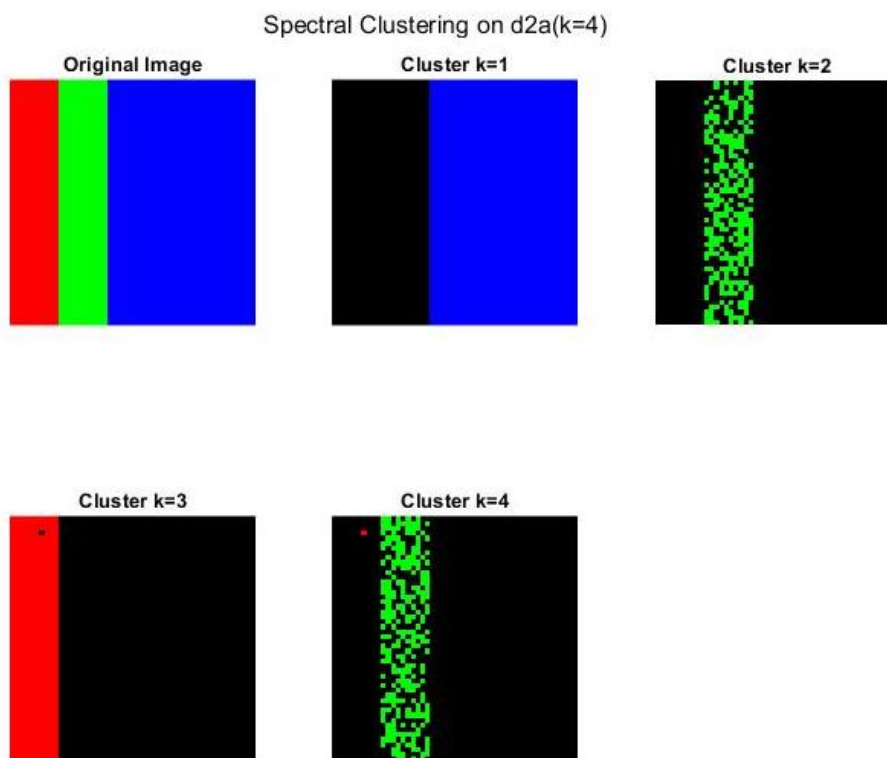
**Εικόνα 2.1 Εφαρμογή της ρουτίνας mySpectralClustering στην d2a για κατάτμηση σε 2 cluster**

Αναμένουμε ότι αλγόριθμος θα κάνει 2 ομάδες όπου στη μια θα υπάρχουν 2 χρώματα και στην άλλη ένα χρώμα. Στο 1<sup>ο</sup> cluster βρίσκονται αποκλειστικά μπλε pixels (μιας και είναι η πλειοψηφία) που έχουν τιμή 1 στον affinity πίνακα, ενώ στο 2<sup>ο</sup> cluster συνυπάρχουν τα κόκκινα και τα πράσινα pixels που έχουν τιμή 1 ή 0.2431 στον affinity.



**Εικόνα 2.2 Εφαρμογή της ρουτίνας *mySpectralClustering* στην *d2a* για κατάτμηση σε 3 cluster**


Εδώ ο αλγόριθμος ομαδοποίησε την εικόνα σε 3 cluster (κόκκινα, πράσινα και μπλε pixel) , όπου στην περίπτωση μας, τα pixels του κάθε cluster είναι απολύτως όμοια (δηλαδή έχουν τιμή 1 στον affinity). Το αποτέλεσμα αυτό ήταν αναμενόμενο καθώς εξ αρχής η εικόνα περιέχει 3 χρωματικές περιοχές άρα 3 διαφορετικές περιοχές φωτεινότητας.



**Εικόνα 2.3 Εφαρμογή της ρουτίνας *mySpectralClustering* στην *d2a* για κατάτμηση σε 4 cluster**


Καθώς στην εικόνα ζουν 3 διαφορετικές τιμές φωτεινότητας υπάρχουν 3 διαφορετικά clusters. Συνεπώς η απαίτηση για 4 cluster θα σπάσει ένα cluster στα 2, όπως παρατηρήσαμε και στην ενότητα 1 με τον d1a.

Spectral Clustering on d2b(k=2)



**Εικόνα 2.4 Εφαρμογή της ρουτίνας *mySpectralClustering* στην *d2b* για κατάτμηση σε 2 cluster**

Ο αλγόριθμος για 2 cluster διέκρινε τις σκούρες περιοχές (cluster k=1) από τις πιο ανοιχτόχρωμες (cluster k=2).



**Εικόνα 2.5 Εφαρμογή της ρουτίνας *mySpectralClustering* στην *d2b* για κατάτμηση σε 3 cluster**

Για 3 cluster παρατηρούμε ότι δημιουργείται ένα cluster με τα πολύ φωτεινά pixels (cluster k=2) το οποίο περιέχει τμήμα των γαντιών του σούπερ μάριο και λευκά τμήματα στις άκρες της εικόνας. Τα cluster k=1 και cluster k=3 έχουν ανοιχτόχρωμες και σκουρόχρωμες περιοχές φωτεινότητας όπως περίπου στην προηγούμενη περίπτωση.



**Εικόνα 2.6 Εφαρμογή της ρουτίνας mySpectralClustering στην d2b για κατάτμηση σε 4 cluster**

Εδώ βλέπουμε ότι το cluster k=1 με τις πολύ φωτεινές περιοχές έχει συλλέξει και άλλα pixels. Το cluster k=4 περιέχει φωτεινές περιοχές ενώ τα clusters k=2, k=3 είναι απόρροια προσπάθειας περαιτέρω ομαδοποίησης του cluster k=3 της προηγούμενης εφαρμογής (εικόνα 2.5). Το cluster k=3 (της εικόνας 2.6) φαίνεται να μην έχει κάποια ουσιαστική πληροφορία αφού περιέχει ένα μόνο pixel το οποίο δεν διαφέρει πολύ από αυτά του cluster k=2.


### Ενότητα 3

#### ❖ 3.1


Στην ενότητα 3.1 παρουσιάζεται η συνάρτηση myNCuts **η οποία υλοποιεί την μη-αναδρομική εκδοχή** της μεθόδου normalized cuts. Η σχεδίαση της myNCuts, η οποία έχει ελαφρώς τροποποιηθεί για τις ανάγκες της εργασίας, είναι αυτή που ακολουθεί. Δέχεται σαν είσοδο τον affinity πίνακα και τον αριθμό k των clusters στα οποία επιθυμούμε να κατατμήσουμε την εικόνα. Παράγει τον μη-κανονικοποιημένο Λαπλασιανό πίνακα. Έπειτα, λύνει το γενικευμένο σύστημα ιδιοτιμών  $Lx = \lambda Dx$  χρησιμοποιώντας για επίλυση το ισοδύναμο σύστημα  $D^{-\left(\frac{1}{2}\right)} * L * D^{-\left(\frac{1}{2}\right)}x = \lambda x$  (όπως υποστηρίζεται και στο paper) και βρίσκει τα k μικρότερα ιδιοδιανύσματα. Ομαδοποιεί τους κόμβους με την συνάρτηση k-means της Matlab. Η extra τροποποίηση είναι ότι πέρα από το διάνυσμα των ετικετών, επιστρέφει και τον πίνακα nxk με τα k μικρότερα ιδιοδιανύσματα διότι θα χρειαστούν στην αναδρομική εκδοχή.

Στη συνέχεια παρουσιάζονται τα αποτελέσματα της μη-αναδρομικής myNCuts στις εικόνες d2a και d2b για k=2,k=3,k=4 clusters καθώς και σύγκριση αυτών με τη μέθοδο spectral clustering.

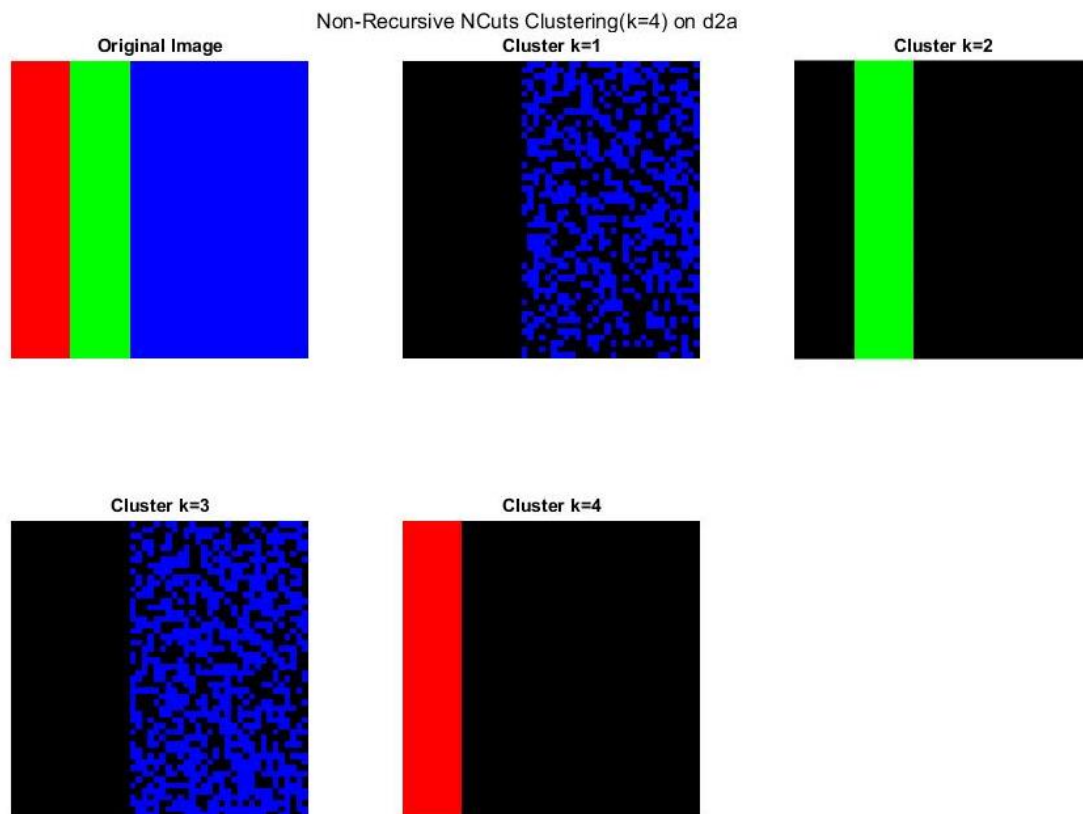
### Non-Recursive NCuts Clustering(k=2) on d2a



*Εικόνα 3.1.1 Εφαρμογή της ρουτίνας myNCuts στην d2a για κατάτμηση σε 2 cluster*




*Εικόνα 3.1.2 Εφαρμογή της ρουτίνας myNCuts στην d2a για κατάτμηση σε 3 cluster*



**Εικόνα 3.1.3 Εφαρμογή της ρουτίνας *myNCuts* στην *d2a* για κατάτμηση σε 2 cluster**


Όσον αφορά τις εικόνες 3.1.1, 3.1.2, 3.1.3 η μέθοδος της μη-αναδρομικής normalized cuts μας δίνει το αναμενόμενο αποτέλεσμα, καθώς η εικόνα *d2a* αποτελεί αρκετά εύκολο πρόβλημα κατάτμησης εικόνας. Στην 3.1.3 παρατηρούμε ότι η απαίτηση 4 cluster σε μια εικόνα που αποτελείται από 3 χρωματικές περιοχές αναγκάζει τη μέθοδο να σπάσει cluster των μπλε pixels σε 2 νέα clusters.



**Εικόνα 3.1.4 Εφαρμογή της ρουτίνας *myNCuts* στην *d2b* για κατάτμηση σε 2 cluster**

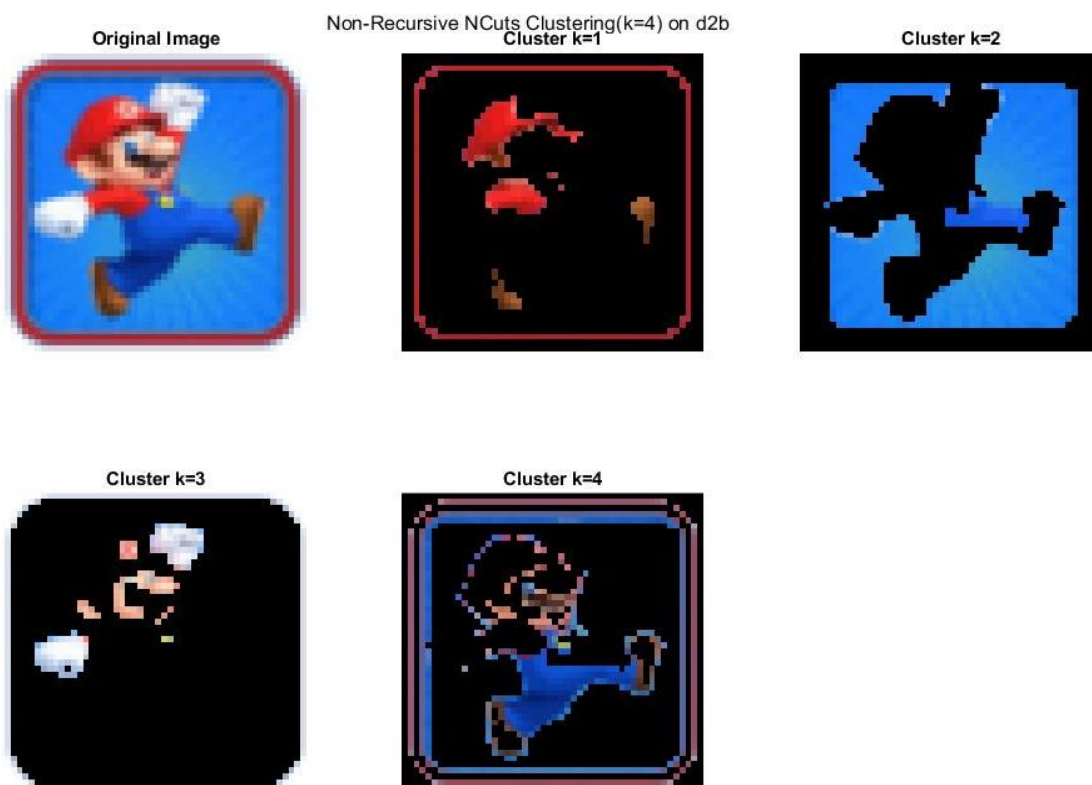
Η μη-αναδρομική μέθοδος normalized cuts για  $k=2$  διαχώρισε τα μπλε pixels του φόντου από τα υπόλοιπα μέλη του σούπερ μάριο κάνοντας μια ικανοποιητική (χρήσιμη) ομαδοποίηση.





*Εικόνα 3.1.5 Εφαρμογή της ρουτίνας myNCuts στην d2b για κατάτμηση σε 3 cluster*

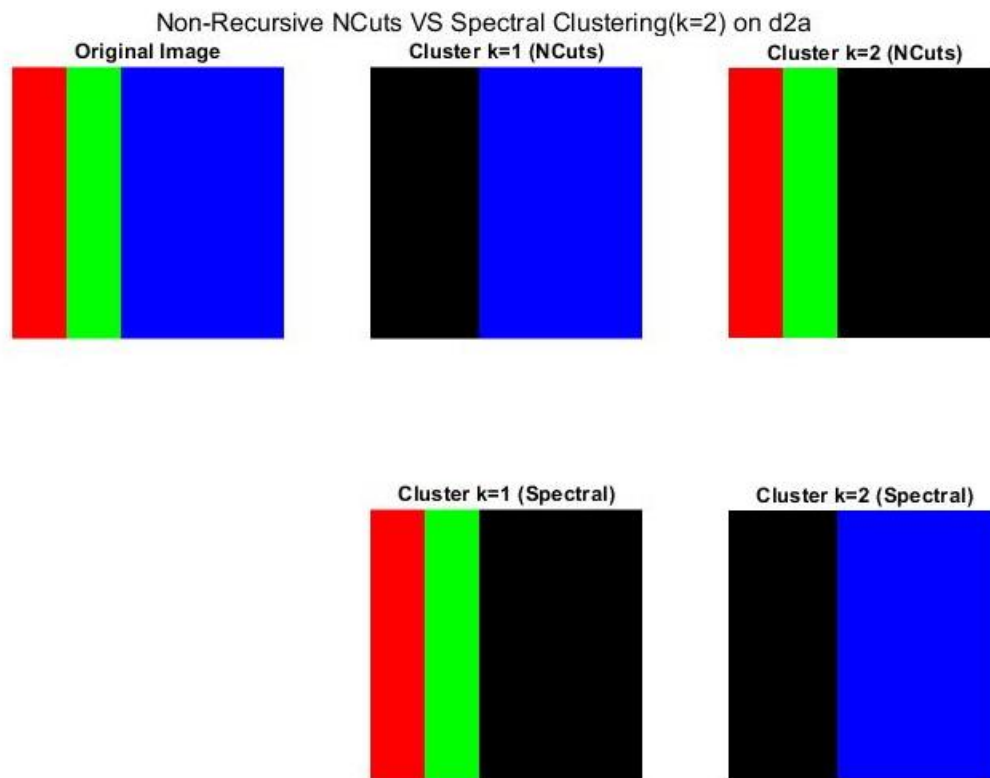
Για  $k=3$  η μη-αναδρομική μέθοδος φαίνεται ουσιαστικά να χωρίζει επιπλέον από το cluster  $k=1$  της **εικόνας 3.1.4** τα χέρια και το πρόσωπο από την υπόλοιπη εικόνα.



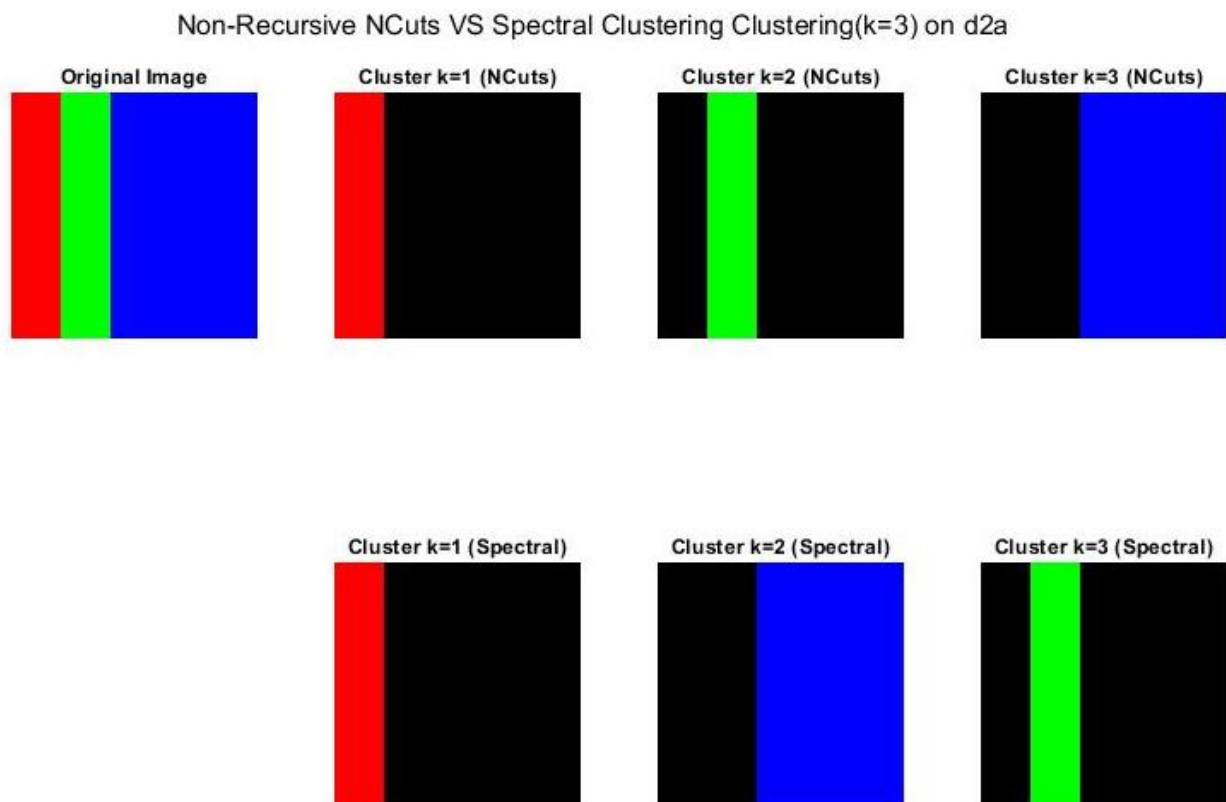
*Εικόνα 3.1.6 Εφαρμογή της ρουτίνας myNCuts στην d2b για κατάτμηση σε 4 cluster*

Για  $k=4$  έχει γίνει επιπλέον διαχωρισμός του παντελονιού του σούπερ μάριο από μπλε φόντο.






Εικόνα 3.1.7 Σύγκριση μη αναδρομικής NCuts με Spectral Clustering(k=2) στην d2a



Εικόνα 3.1.8 Σύγκριση μη αναδρομικής NCuts με Spectral Clustering(k=3) στην d2a

Non-Recursive NCuts VS Spectral Clustering Clustering(k=4) on d2a



Εικόνα 3.1.9 Σύγκριση μη αναδρομικής NCuts με Spectral Clustering(k=4) στην d2a

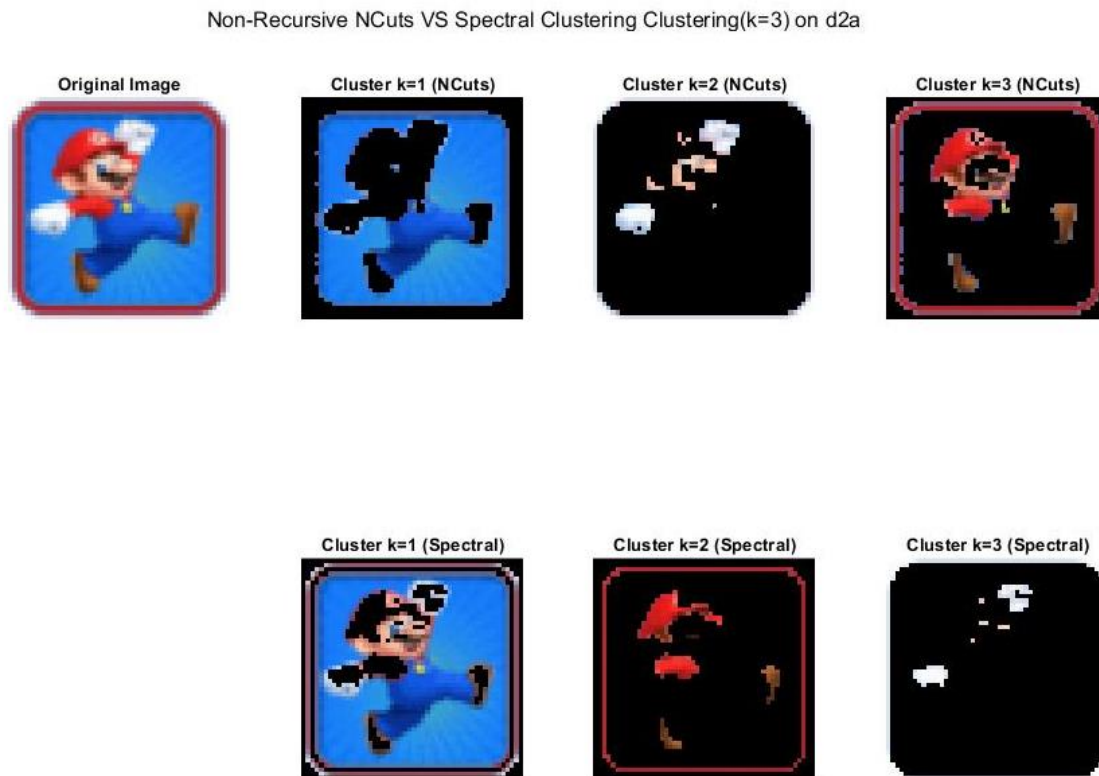
Όσον αφορά τη σύγκριση της μη αναδρομικής NCuts με Spectral Clustering (για k=2, k=3, k=4) στην εικόνα d2a (βλ. εικόνες 3.1.7, 3.1.8, 3.1.9) δεν παρατηρούμε κάποια διαφορά καθώς η εικόνα αποτελεί εύκολη περίπτωση clustering. Η μονή διαφορά είναι στην περίπτωση όπου ζητάμε 4 clusters, όπου η NCuts έσπασε περαιτέρω το cluster των μπλε pixels ενώ η Spectral Clustering έσπασε τα πράσινα pixels.

Non-Recursive NCuts VS Spectral Clustering(k=2) on d2b



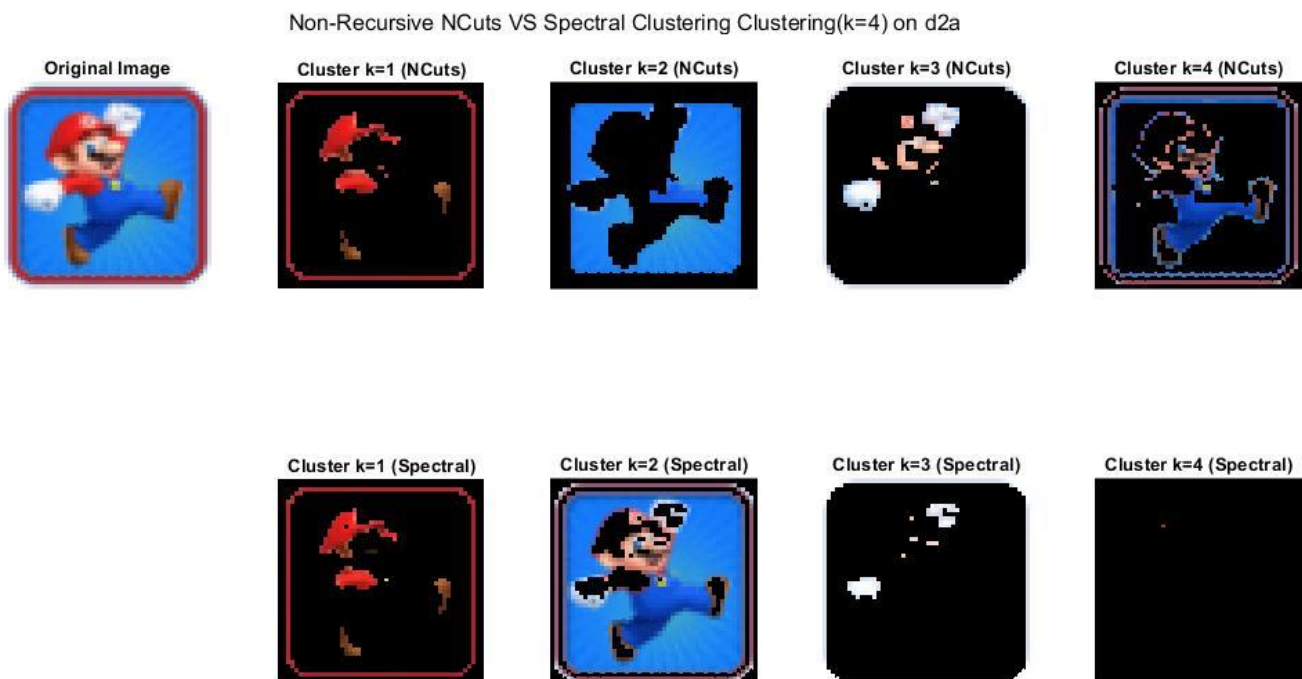
Εικόνα 3.1.10 Σύγκριση μη αναδρομικής NCuts με Spectral Clustering(k=2) στην d2b

Για  $k=2$  η μέθοδος NCuts έκανε πιο ουσιαστική ομαδοποίηση της πληροφορίας σε σχέση με τη μέθοδο Spectral Clustering η οποία έχει κάνει πιο άνιση κατανομή στις φωτεινότητες που ομαδοποίησε. Η διαφορά οφείλεται στη λύση του προβλήματος των ιδιοτιμών στον πυρήνα κάθε μεθόδου.



**Εικόνα 3.1.11 Σύγκριση μη αναδρομικής NCuts με Spectral Clustering( $k=3$ ) στην d2b**

Για  $k=3$  παρατηρούμε ξανά ότι η μέθοδος NCuts έκανε πιο αποτελεσματική δουλειά σε σχέση με την Spectral Clustering. Αποδεικνύεται μέχρι στιγμής ότι σε πιο περίπλοκες εικόνες η Spectral Clustering είναι λιγότερο αποτελεσματική.



**Εικόνα 3.1.12 Σύγκριση μη αναδρομικής NCuts με Spectral Clustering( $k=4$ ) στην d2b**

Για  $k=4$  βλέπουμε ότι η μέθοδος NCuts έσπασε το cluster των μπλε pixels διαχωρίζοντας το παντελόνι και το περίγραμμα του σούπερ μάριο από το φόντο, δίνοντας μια πιο χρήσιμη πληροφορία σε σχέση με την Spectral Clustering η οποία δημιούργησε ένα cluster με ένα μόνο pixel από το καπέλο του σούπερ μάριο. Επίσης το cluster που περιέχει τα χέρια είναι καλύτερα ομαδοποιημένο στη μέθοδο των normalized cuts.

**Ολικό συμπέρασμα:** Σε εικόνες με απλή δομή όπως η d2a δεν ξεχώρισε κάποιος αλγόριθμος ως προς τα αποτελέσματά του, οπότε σε μια τέτοια περίπτωση θα επιλέγαμε τον πιο φθηνό σε υπολογισμούς. Σε εικόνες με πιο σύνθετη δομή όπως η d2b, η μέθοδος Normalized Cuts αποδείχθηκε πιο ουσιαστικής και αποτελεσματικής σε σχέση με την Spectral Clustering. **Η διαφορά τους εντοπίζεται στο πρόβλημα ιδιοτιμών που λύνουν και επομένως στον τρόπο με τον οποίο επιλέγουν να λύσουν το graph clustering.**

### ❖ 3.2

Στην ενότητα αυτή παρουσιάζεται η λειτουργία της αναδρομικής μεθόδου ncuts για 1 βήμα και η λειτουργία υπολογισμού της μετρικής ncut.

Για την αναδρομική μέθοδο έχει υλοποιηθεί η συνάρτηση **myNCutsRec** και η **myNCutsPartition**. Η **myNCutsRec** δέχεται ως είσοδο τον affinity πίνακα και τα κατώφλια T1, T2 της μεθόδου. Η συνάρτηση στο πρώτο της βήμα ορίζει ένα ενιαίο cluster «Seg» που περιέχει όλα τα pixels (nodes), θέτει την ταυτότητα Id του καλούντα ως «ROOT» ώστε να καταγράφεται η πορεία των κλήσεων και καλεί την **myNCuts** για  $k=2$  για να γίνει η πρώτη κατάτμηση. Ανανεώνει το Seg (μεταβλητή τύπου cell) ώστε να περιέχει τα 2 clusters που παρήχθησαν. Καλεί την **calculateNcut** (θα περιγράψει μετά) για να υπολογίσει την τιμή της μετρικής ncut. Στη συνέχεια τσεκάρει τα κατώφλια T1,T2 για να αποφασίσει αν θα τερματίσει τη λειτουργία της ή αν θα συνεχίσει σε επιπλέον κατάτμηση. Σε περίπτωση που συνεχίσει σε κατάτμηση καλεί την **myNCutsPartition** για κάθε ένα από τα 2 clusters δίνοντας είσοδο το Segment με τα pixels του κάθε cluster, τον affinity για το νέο cluster, τα κατώφλια T1,T2, καθώς και ένα προσδιοριστικό id για κάθε «παιδί» (A ή B). Η **myNCutsPartition** καλείται αναδρομικά όσο ικανοποιούνται οι περιορισμοί για τα κατώφλια. Η διαδικασία **myNCutsRec** επιστρέφει στο τέλος ένα cell vector Seg με τα clusters που δημιουργήθηκαν, τις τιμές Ncut των κόμβων «φύλλων» που σχηματίζονται στο δυαδικό δένδρο ώστε να σιγουρευτούμε ότι η διαδικασία τελείωσε επιτυχώς, και ένα cell vector Id που δείχνει με ποια διαδρομή δημιουργήθηκε κάθε cluster στο δυαδικό δένδρο.

Όσον αφορά την **myNCutsPartition**, η φιλοσοφία της είναι παρόμοια. Καλεί την **myNCuts** για  $k=2$ , βρίσκει τα pixels (nodes) των 2 νέων clusters, υπολογίζει τη μετρική ncut, ελέγχει τα κατώφλια T1, T2 και σε περίπτωση που ικανοποιούνται καλεί ξανά τον εαυτό της για κάθε ένα από τα 2 clusters, το νέο affinity πίνακα για κάθε cluster, τα κατώφλια T1, T2 και το προσδιοριστικό id (A ή B). Επιστρέφει τα Segments με τα clusters που δημιουργήθηκαν, τις τιμές Ncut των κόμβων «φύλλων» και τα Id των διαδρομών με τις οποίες δημιουργήθηκαν τα clusters. Στο τέλος του σώματος της συνάρτησης γίνεται συνένωση των τιμών που παράγονται από το παιδί A και το παιδί B του δένδρου.

Για την υλοποίηση της **calculateNcut**, σύμφωνα με το paper που δόθηκε, η ελάχιστη τιμή της μετρικής ncut για τα δυο σέτ A,B μπορεί να υπολογιστεί ως:

$$\min_{A,B} Ncut(A, B) = \min_y \frac{y^T(D - W)y}{y^T D y}$$

Και κάνοντας κατάλληλες παραδοχές για τις τιμές του  $y$ , η ελάχιστη τιμή του 2<sup>ου</sup> μέλους μπορεί να υπολογιστεί λύνοντας το γενικευμένο σύστημα ιδιοτιμών:


$$(\mathbf{D} - \mathbf{W})\mathbf{y} = \lambda \mathbf{D}\mathbf{y}$$

το οποίο μπορεί να μετασχηματιστεί στο:

$$\mathbf{D}^{-\frac{1}{2}}(\mathbf{D} - \mathbf{W})\mathbf{D}^{-\frac{1}{2}}\mathbf{z} = \lambda \mathbf{z},$$

Το 2ο μικρότερο ιδιοδιάνυσμα είναι αυτό που ελαχιστοποιεί την ποσότητα. Έτσι η **calculateNcut** δέχεται τον **affinity** πίνακα και το 2ο μικρότερο ιδιοδιάνυσμα  $y$  και υπολογίζει το minimum cut.

Στη συνέχεια παρουσιάζονται οι εφαρμογές της **myNCutsRec** για 1 βήμα στις d2a, d2b, σύγκριση με τη μέθοδο Spectral Clustering για  $k=2$ , καθώς και οι τιμές της μετρικής Ncut (πάνω στις εικόνες). Προκειμένου να αναγκάσουμε την αναδρομική να τρέξει για 1 βήμα επιλέχθηκαν κατώφλια 0.50 και 0.70 αντίστοιχα για το ncut. Οι λειτουργίες είναι και στο demo3b.m



Εικόνα 3.2.1 Εφαρμογή της ρουτίνας *myNCutsRec* (1 βήμα) στην d2a


Recursive NCuts Clustering (1 step) on d2b

Ncut value: 0.75113



**Εικόνα 3.2.2 Εφαρμογή της ρουτίνας *myNCutsRec* (1 βήμα) στην d2b**


Τα αποτελέσματα, τόσο για την d2a όσο και για την d2b είναι τα ίδια με αυτά της μη-αναδρομικής ncuts για k=2.



**Εικόνα 3.2.3 Σύγκριση αναδρομικής NCuts (1 βήμα) με Spectral Clustering στην d2a**

Δεν παρατηρούμε κάποια διαφορά στην αναδρομική NCuts και στην Spectral Clustering στην d2a.






**Εικόνα 3.2.4 Σύγκριση αναδρομικής NCuts (1 βήμα) με Spectral Clustering στην d2b**

Στην d2b παρατηρούμε ότι η κατάτμηση της αναδρομικής NCuts (1 βήμα) , η οποία είναι στην ουσία η μη-αναδρομική για  $k=2$ , είναι πιο αποτελεσματική σε σχέση με το Spectral Clustering.

### ❖ 3.3


Στην ενότητα αυτή παρουσιάζεται η ολοκληρωμένη αναδρομική μέθοδος normalized Cuts. Καθώς το κατώφλι 0.2 δεν μπορούσε να προκαλέσει αναδρομές, επιλέχθηκαν κατώφλια ncut 0.51 και 0.80 στην d2a και d2b αντίστοιχα, με στόχο την δημιουργία 3 clusters.

Στη συνέχεια παρουσιάζονται τα αποτελέσματα της ολοκληρωμένης αναδρομικής μεθόδου στην d2a και d2b και σύγκριση αυτών με μέθοδο Spectral Clustering και μη αναδρομικής Ncuts για  $k=2$ ,  $k=3$ . Οι λειτουργίες αυτές υλοποιούνται στο demo3c.m.



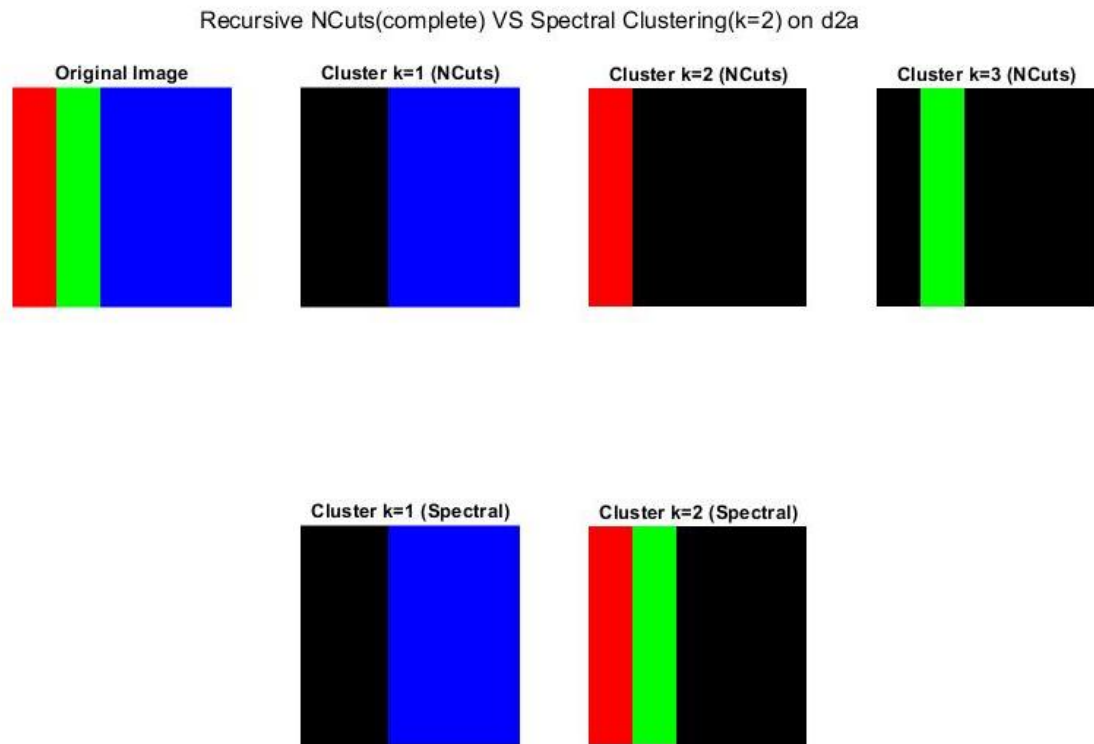
**Εικόνα 3.3.1 Εφαρμογή της ρουτίνας *myNCutsRec* (ολοκληρωμένη) στην *d2a***

Η αναδρομική κάνει την αναμενόμενη κατάτμηση στην *d2a*.




**Εικόνα 3.3.2 Εφαρμογή της ρουτίνας *myNCutsRec* (ολοκληρωμένη) στην *d2b***

Το αποτέλεσμα, αρκετά ικανοποιητικό, μοιάζει στην μη-αναδρομική για  $k=3$  και θα σχολιαστεί στη μεταξύ τους σύγκριση.



**Εικόνα 3.3.3 Σύγκριση της αναδρομικής μεθόδου NCuts με Spectral Clustering (k=2) στην d2a**



**Εικόνα 3.3.4 Σύγκριση της αναδρομικής μεθόδου NCuts με Spectral Clustering (k=3) στην d2a**

Για τις εικόνες **3.3.3**, **3.3.4** δεν υπάρχει κάποιο ιδιαίτερο σχόλιο στο αποτέλεσμα καθώς η d2a είναι αρκετά τετριμμένη περίπτωση.



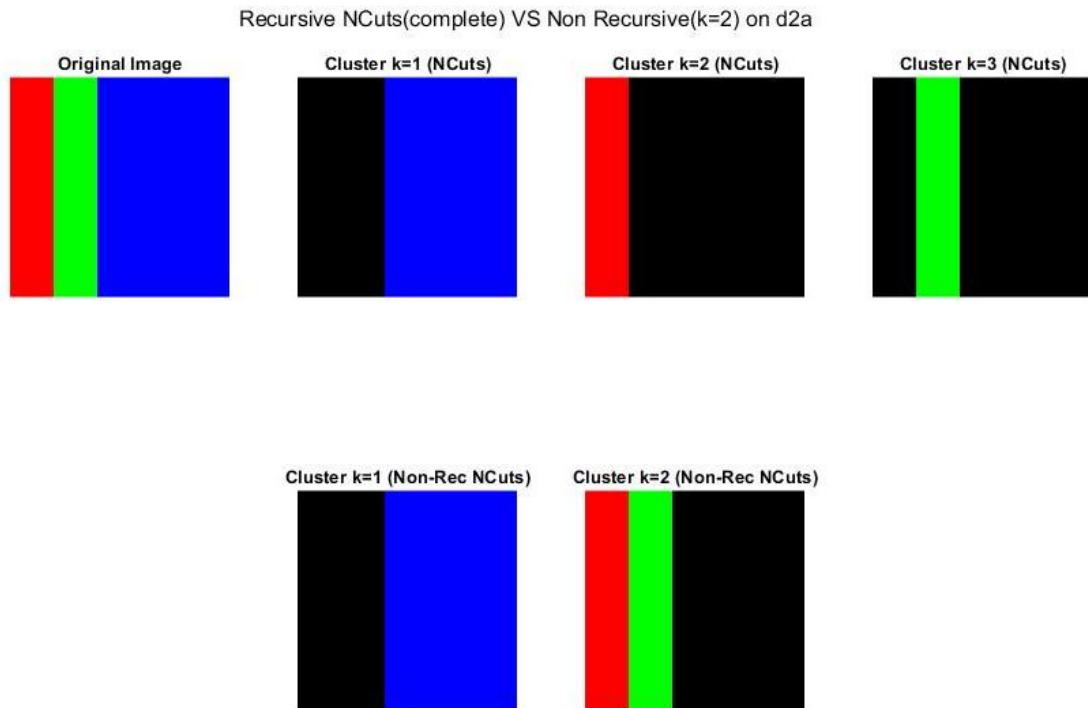
**Εικόνα 3.3.5 Σύγκριση της αναδρομικής μεθόδου NCuts με Spectral Clustering ( $k=2$ ) στην d2b**

Είναι εμφανές ότι αφενός η Spectral Clustering παράγει υποδέεστερα αποτελέσματα και αφετέρου είναι χρησιμότερη η δημιουργία 3 clusters για τη δομή της εικόνας.

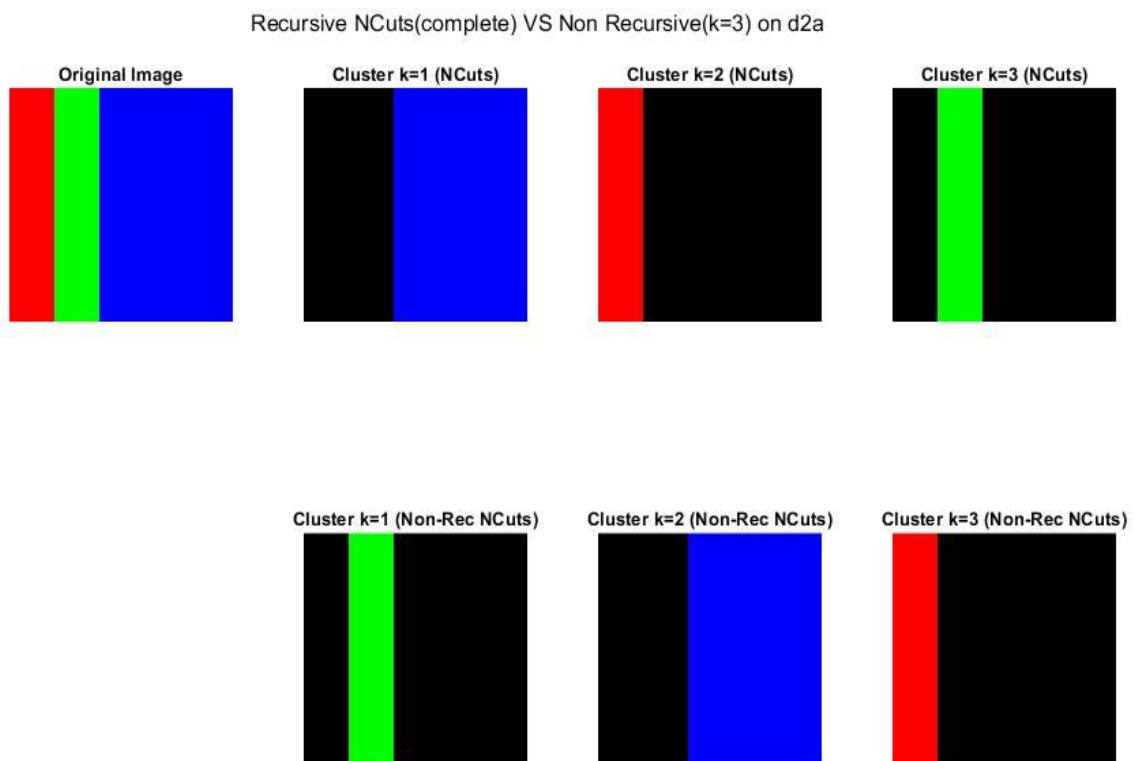


**Εικόνα 3.3.6 Σύγκριση της αναδρομικής μεθόδου NCuts με Spectral Clustering ( $k=3$ ) στην d2b**

Για  $k=3$  clusters η Spectral Clustering βελτιώνεται λίγο αλλά η αναδρομική επιτυγχάνει πιο εύστοχη ομαδοποίηση.



**Εικόνα 3.3.7 Σύγκριση της αναδρομικής μεθόδου NCuts με μη-αναδρομική ( $k=2$ ) στην d2a**



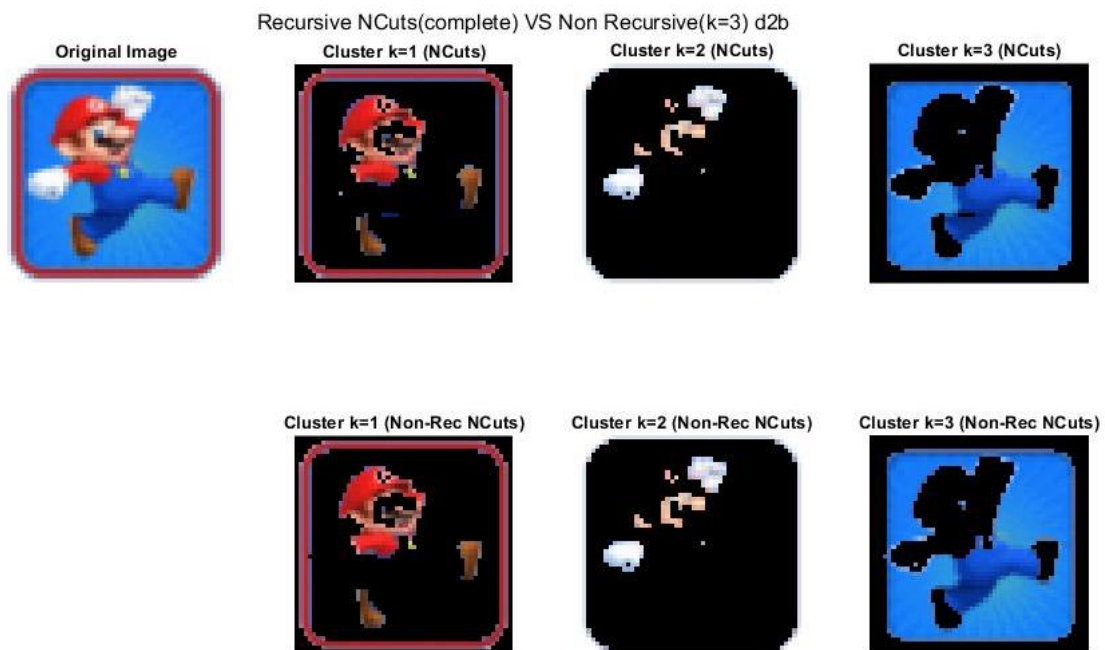
**Εικόνα 3.3.8 Σύγκριση της αναδρομικής μεθόδου NCuts με μη-αναδρομική ( $k=3$ ) στην d2a**

Για τις εικόνες **3.3.7**, **3.3.8** δεν υπάρχει κάποιο ιδιαίτερο σχόλιο στο αποτέλεσμα, παρουσιάζονται πιο πολύ για τις ανάγκες του report.

Recursive NCuts(complete) VS Non Recursive( $k=2$ ) on d2b



**Εικόνα 3.3.9 Σύγκριση της αναδρομικής μεθόδου NCuts με μη-αναδρομική ( $k=2$ ) στην d2b**



**Εικόνα 3.3.10 Σύγκριση της αναδρομικής μεθόδου NCuts με μη-αναδρομική ( $k=3$ ) στην d2b**

Για τις εικόνες 3.3.9, 3.3.10 η αναδρομική και μη αναδρομική μέθοδος παρουσιάζουν κάποιες διαφορές σε λεπτομέρειες με την αναδρομική να φαίνεται λίγο πιο πετυχημένη.



## Παράρτημα – Περιγραφή extra συναρτήσεων

Για την παρουσίαση των αποτελεσμάτων έχουν δημιουργηθεί επιπλέον 2 συναρτήσεις: η **myLabels2Seg** και η **myImClusters**.

Η **myLabels2Seg** αναλαμβάνει να δημιουργήσει ένα cell vector Seg που περιλαμβάνει τα ομαδοποιημένα pixels δηλαδή τα clusters της εικόνας. Δέχεται ως όρισμα το διάνυσμα με τις ετικέτες, τον αριθμό των clusters, και την αρχική εικόνα.

Η **myImClusters** λαμβάνει την αρχική εικόνα και το cell vector Seg της προηγούμενης διαδικασίας και παράγει τις εικόνες των clusters που δημιουργήθηκαν. Η έξοδος της δηλαδή στην περίπτωση μας είναι τύπου 4-D (clusters \* MxNxη εικόνες). Στο σώμα της η συνάρτηση εφαρμόζει κάποια κατάλληλα rotations και flips στην αρχική εικόνα και την μετασχηματίζει σε μορφή πίνακα όπου η κάθε γραμμή αντιστοιχεί στο άξον pixel i. Αρχικοποιεί τις εικόνες των clusters στο 0 (χαμηλή φωτεινότητα) και χρησιμοποιώντας τον μετασχηματισμένο πίνακα καθώς και τα δεδομένα Seg αντιγράφει τα κατάλληλα pixels σε κάθε εικόνα του cluster. Τέλος για τη σωστή απεικόνιση των δεδομένων εφαρμόζει πάλι κατάλληλα rotations και flips.